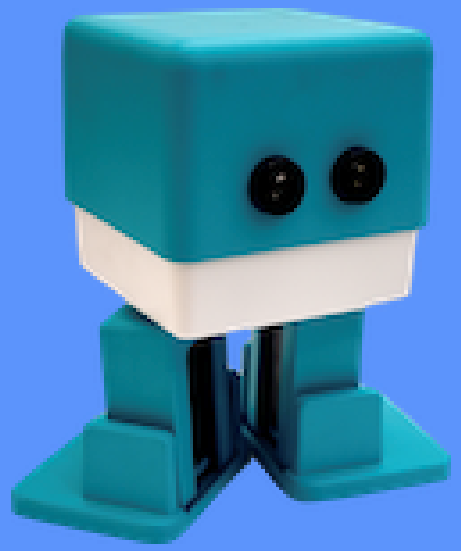

Imitation Learning in Super Mario Bros: Behavior Cloning and DAgger Using Privileged Information

Μαρία - Νίκη Ζωγράφου up1096060@ac.upatras.gr

Νικόλαος Γέροντας up1092813@ac.upatras.gr

Στόχος Εργασίας

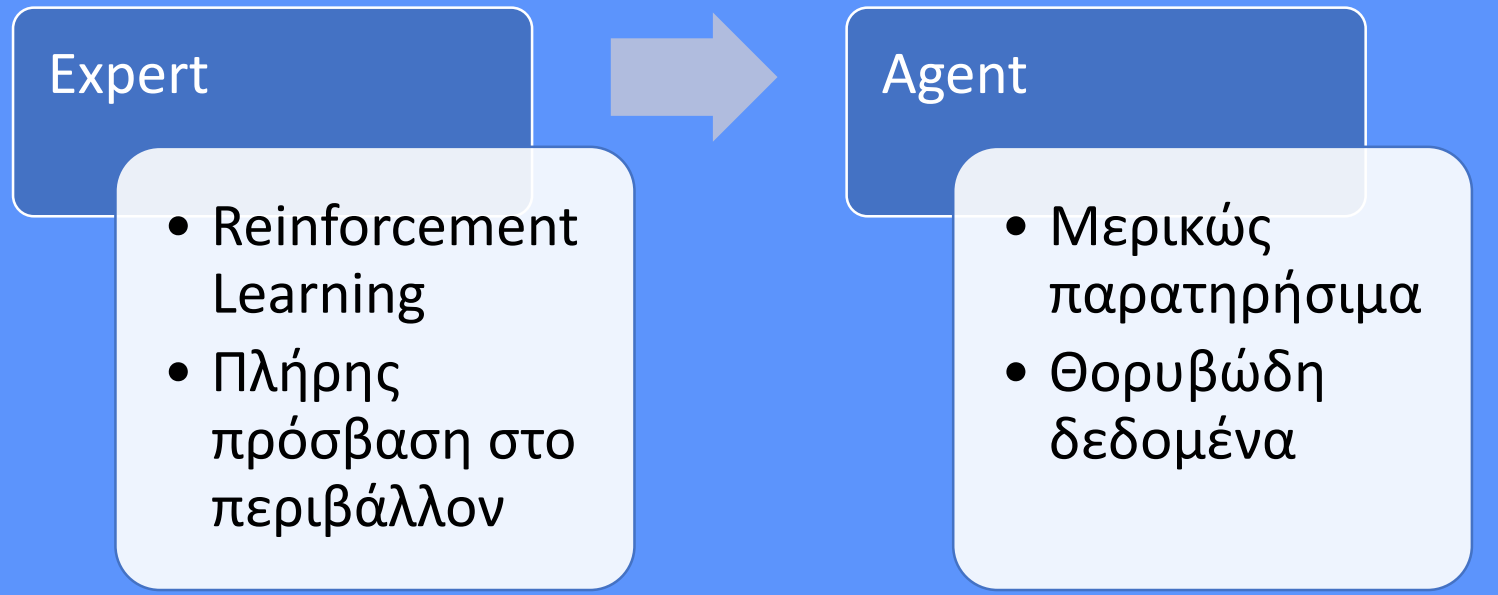

Εκπαίδευση των Agents

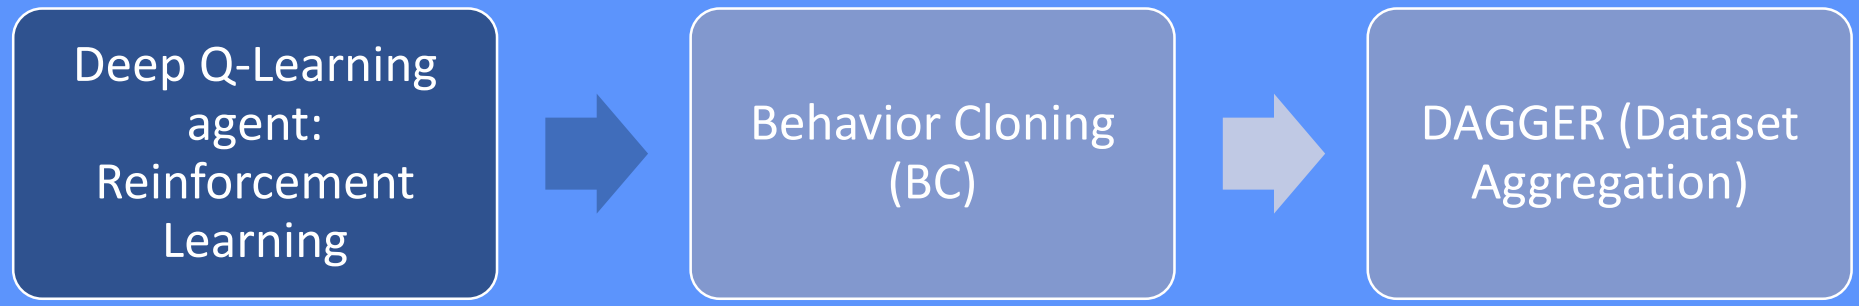

Expert: Deep Q-Learning

Q-learning:

$$Q(s,a) = Q(s,a) + a * (r + \gamma \, max_z Q(s',a') - Q(s,a))$$

Q: Q-table
s: state
a: action
s': next state
a': action with max future reward

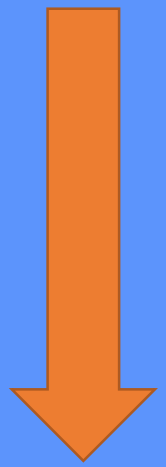

Αντικατάσταση Q-table
με νευρωνικό δίκτυο

Deep Q-learning:

Q – value function: $Q(s,a;\theta)$, όπου θ οι παράμετροι του νευρωνικού

Expert: Deep Q-Learning

Input
- 4 τελευταία frames
- μετατροπή σε grayscale
- 84x84 pixels
- frame skipping

Reward Shaping
- Πρόοδος προς τα δεξιά +0.1
- Χρονικό penalty -0.1
- Ποινή για θάνατο -10
- Τερματισμός +100

Loss function: **MSE** Loss

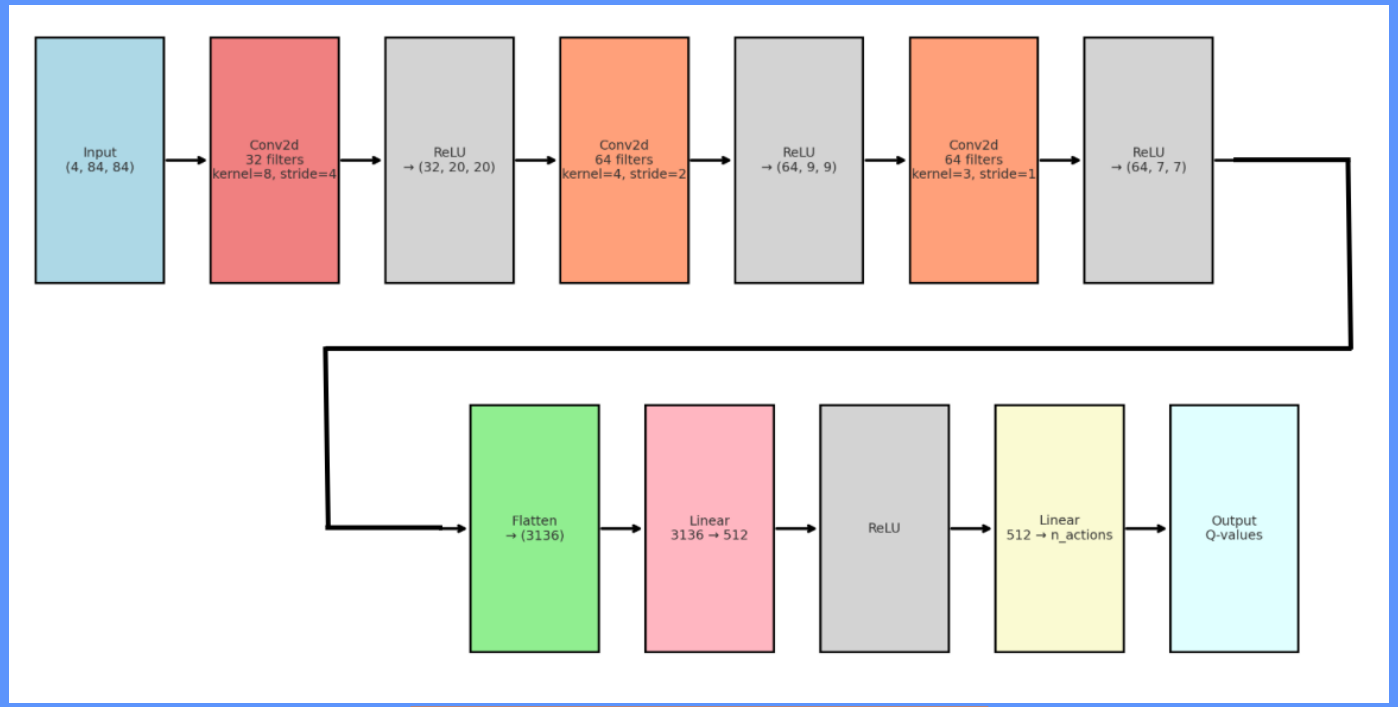

Αρχιτεκτονική νευρωνικού

Imitation Learning

Σύνηθες πρόβλημα:
Φτάνει σε καταστάσεις που δεν έχει δει ο expert

DAgger (Dataset Aggregation)

Ο DAGGER υπερβαίνει τους περιορισμούς του Behavior Cloning επειδή διορθώνει το distributional shif!

DAgger με Behaviour Cloning Warm up

Dagger + Σύντομο στάδιο behavior cloning → Expert agreement → Επιτάχυνση σύγκλισης του Dagger!

Σταθεροποίηση εκμάθησης της πολιτικής με ~60 επαναλήψεις, σε αντίθεση με τις ~1400 του «απλού» Dagger.

Στατιστική Αξιολόγηση (final loss)

Plain DAGGER

- Median: 0.41
- 25%-75%: 0.34 - 0.42
- 10%-90%: 0.24 - 0.45
- Min-Max: 0.04 - 0.48

DAGGER + BC Warmup

Improvement: -55.5%

- Median: 0.18
- 25%-75%: 0.07 - 0.33
- 10%-90%: 0.05 - 0.38
- Min-Max: 0.04 - 0.42

STAGE COMPLETION:

Plain DAGGER: 70.0% (20 runs)
BC Warmup DAGGER: 100.0% (20 runs)
Improvement: +30.0%